

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

KHOA ĐIỆN TỬ - VIỄN THÔNG

THỰC HÀNH XỬ LÝ TÍN HIỆU SỐ

LỚP 24DTV_DKD2

BẢN MÔ TẢ ĐỒ ÁN LẤY ĐIỂM CỘNG

NHẬN DẠNG ĐIỀU CHẾ SỐ TỰ ĐỘNG
TRONG KÊNH VÔ TUYẾN NHIỀU
BẰNG XỬ LÝ TÍN HIỆU SỐ VÀ HỌC SÂU

DEEPPDSP-AMC

*Automatic Digital Modulation Classification in Noisy Radio Channels Using Digital Signal
Processing and Deep Learning*

Giảng viên : ThS. HUỖNH QUỐC THỊNH
Sinh viên thực hiện : LƯƠNG HẢI LONG
Mã số sinh viên : 22207056

Thành phố Hồ Chí Minh

Tháng 08 năm 2026

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

KHOA ĐIỆN TỬ - VIỄN THÔNG

THỰC HÀNH XỬ LÝ TÍN HIỆU SỐ

LỚP 24DTV_DKD2

BẢN MÔ TẢ ĐỒ ÁN LẤY ĐIỂM CỘNG

NHẬN DẠNG ĐIỀU CHẾ SỐ TỰ ĐỘNG
TRONG KÊNH VÔ TUYẾN NHIỀU
BẰNG XỬ LÝ TÍN HIỆU SỐ VÀ HỌC SÂU

DEEPPDSP-AMC

Automatic Digital Modulation Classification in Noisy Radio Channels Using Digital Signal Processing and Deep Learning

Đối tượng	: 6 kiểu điều chế số; khung I/Q 256 mẫu
Dải khảo sát	: SNR từ -12 dB đến 18 dB
Mô hình	: Random Forest, CNN 1-D và tổ hợp xác suất
Kết quả chính	: Hybrid macro-F1 0,7340 đạt 90% accuracy từ 9 dB
Video demo	: youtu.be/yl5Sk6plWXg

Giảng viên : ThS. HUỖNH QUỐC THỊNH
Sinh viên thực hiện : LƯƠNG HẢI LONG
Mã số sinh viên : 22207056

CAM KẾT

Tôi cam đoan các số liệu và kết quả trong bản mô tả này được tạo từ notebook đi kèm với hạt giống ngẫu nhiên cố định. Các kết quả accuracy, macro-F1, thời gian huấn luyện và độ trễ suy luận đều được lấy từ lần chạy đã lưu; không dùng số liệu thay thế từ bài báo hoặc kho mã khác.

Mã nguồn tham khảo, thư viện phần mềm và tài liệu học thuật được nêu rõ trong phần tài liệu tham khảo. Những giới hạn của dữ liệu mô phỏng và phạm vi đánh giá được trình bày cùng kết quả. Tôi chịu trách nhiệm kiểm tra lại nội dung, mã nguồn và sản phẩm nộp.

Thành phố Hồ Chí Minh, tháng 08 năm 2026

LƯƠNG HẢI LONG

MSSV: 22207056

TÓM TẮT

Đề án xây dựng một hệ thống nhận dạng điều chế tự động cho sáu dạng tín hiệu số BPSK, QPSK, 8PSK, 16QAM, 2FSK và 4FSK. Dữ liệu gồm 6.600 khung I/Q, mỗi khung 256 mẫu, được sinh cân bằng trên 11 mức SNR từ -12 dB đến 18 dB. Chuỗi mô phỏng có tạo dạng xung root-raised-cosine, lệch pha, sai lệch tần số sóng mang, đa đường nhẹ và nhiễu Gaussian trắng cộng.

Hệ thống gồm hai nhánh. Nhánh học máy trích 18 đặc trưng DSP trong miền biên độ, pha, moment phức và phổ rồi huấn luyện Random Forest. Nhánh học sâu dùng CNN 1-D nhận tensor bốn kênh gồm I, Q, biên độ và sai phân pha. Hệ số tổ hợp xác suất được chọn trên tập validation, sau đó khóa trước khi đánh giá tập test độc lập.

Trên 1.320 khung test, Random Forest đạt accuracy 58,48% và macro-F1 0,5817 CNN đạt 71,82% và 0,7201. Mô hình hybrid đạt accuracy 73,48%, macro-F1 0,7340 và chạm mốc 90% accuracy từ 9 dB. Kết quả cho thấy đặc trưng học sâu và đặc trưng DSP có tính bổ sung trong điều kiện mô phỏng. Đề án chưa thay thế đánh giá trên tín hiệu SDR thực; đây là hướng mở rộng chính.

Từ khóa: nhận dạng điều chế tự động, tín hiệu I/Q, FFT, mật độ phổ công suất, Random Forest, CNN 1-D, SNR.

ABSTRACT

This project develops an automatic modulation classification system for six digital modulation families: BPSK, QPSK, 8PSK, 16QAM, 2FSK, and 4FSK. The balanced synthetic dataset contains 6.600 complex baseband frames, each with 256 I/Q samples, over eleven SNR levels from -12 dB to 18 dB. The channel model includes root-raised-cosine pulse shaping, phase offset, carrier-frequency offset, mild multipath, and additive white Gaussian noise.

Two classification branches are evaluated. The machine-learning branch extracts 18 DSP features from amplitude, phase, higher-order complex moments, and spectrum, followed by a Random Forest classifier. The deep-learning branch uses a compact one-dimensional CNN with four input channels: I, Q, magnitude, and phase difference. A probability fusion weight is selected only on the validation set and then frozen for the independent test set.

On 1.320 test frames, the Random Forest reaches 58,48% accuracy and 0,5817 macro-F1; the CNN reaches 71,82% and 0,7201. The hybrid model reaches 73,48% accuracy and 0,7340 macro-F1, attaining 90% accuracy from 9 dB. The experiment supports the complementary use of engineered DSP features and learned temporal features under the stated simulation assumptions. Validation with over-the-air SDR captures remains future work.

Keywords: automatic modulation classification, I/Q signal, digital signal processing, Random Forest, one-dimensional CNN, signal-to-noise ratio.

MỤC LỤC

CAM KẾT	i
TÓM TẮT	ii
ABSTRACT	iii
MỤC LỤC	iv
DANH SÁCH TỪ VIẾT TẮT	vi
DANH SÁCH HÌNH	vii
DANH SÁCH BẢNG	viii
1 GIỚI THIỆU	1
1.1 Bối cảnh và lý do chọn đề tài	1
1.2 Câu hỏi nghiên cứu	1
1.3 Mục tiêu	1
1.4 Liên hệ với nội dung học phần	2
1.5 Phạm vi và giả thiết	2
1.6 Đóng góp thực hiện	2
1.7 Cấu trúc báo cáo	3
2 CƠ SỞ LÝ THUYẾT	4
2.1 Biểu diễn bằng gốc phức	4
2.2 Ánh xạ ký hiệu số	4
2.3 Tạo dạng xung RRC và tích chập	5
2.4 Mô hình kênh	5
2.5 Phân tích Fourier và mật độ phổ công suất	5
2.6 Đặc trưng DSP	6
2.7 Random Forest	6
2.8 CNN 1-D và tổ hợp xác suất	7
2.9 Chỉ số đánh giá	7
3 THIẾT KẾ THÍ NGHIỆM	8
3.1 Kiến trúc tổng thể	8
3.2 Thiết kế dữ liệu	8
3.3 Các lớp điều chế	9
3.4 Chia dữ liệu và chống rò rỉ	9
3.5 Hai nhánh biểu diễn	9
3.6 Siêu tham số	10
3.7 Quy trình đánh giá	10
4 TRIỂN KHAI NOTEBOOK VÀ ỨNG DỤNG DEMO	11
4.1 Môi trường phần mềm	11
4.2 Tạo xung RRC	11
4.3 Mô phỏng AWGN theo công suất đo	12
4.4 Trích đặc trưng DSP	12
4.5 Tạo tensor CNN	13
4.6 Chọn hệ số fusion	13
4.7 Suy luận tương tác trên ứng dụng demo	13
4.8 Kiểm tra tự động	15
4.9 Đầu ra máy tạo	15
5 KẾT QUẢ VÀ THẢO LUẬN	16
5.1 Kiểm tra tín hiệu mô phỏng	16
5.2 Không gian đặc trưng DSP	19
5.3 Quá trình huấn luyện CNN	19
5.4 Kết quả tổng thể	20
5.5 Ma trận nhầm lẫn	21
5.6 Ảnh hưởng của SNR	23

5.7	Hiệu năng theo lớp	24
5.8	Độ quan trọng đặc trưng	25
5.9	Độ trễ cục bộ và demo	25
5.10	Trả lời câu hỏi nghiên cứu	26
6	KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	27
6.1	Kết quả đạt được	27
6.2	Hạn chế	27
6.3	Hướng phát triển	27
6.4	Kết luận cuối	28
	TÀI LIỆU THAM KHẢO	29
	PHỤ LỤC A — MÃ NGUỒN TRIỂN KHAI CHỌN LỌC	30
A.1.	Sinh bộ hệ số RRC	30
A.2.	Chèn AWGN theo công suất đo	31
A.3.	Nhóm đặc trưng phổ	31
A.4.	Tạo tensor bốn kênh	31
A.5.	Chọn hệ số fusion	32
A.6.	Suy luận trực tiếp cho ứng dụng demo	33
A.7.	Đối chiếu nguồn mở	34

DANH SÁCH TỪ VIẾT TẮT

Ký hiệu	Tiếng Anh	Giải thích
AMC	Automatic Modulation Classification	Nhận dạng điều chế tự động
AWGN	Additive White Gaussian Noise	Nhiều Gaussian trắng cộng
CNN	Convolutional Neural Network	Mạng nơ-ron tích chập
CFO	Carrier Frequency Offset	Sai lệch tần số sóng mang
DFT/FFT	Discrete/Fast Fourier Transform	Biến đổi Fourier rời rạc/nhanh
DSP	Digital Signal Processing	Xử lý tín hiệu số
FSK	Frequency-Shift Keying	Điều chế dịch tần
I/Q	In-phase/Quadrature	Hai thành phần tín hiệu băng gốc phức
PAPR	Peak-to-Average Power Ratio	Tỷ số công suất đỉnh trên trung bình
PSK	Phase-Shift Keying	Điều chế dịch pha
PSD	Power Spectral Density	Mật độ phổ công suất
QAM	Quadrature Amplitude Modulation	Điều chế biên độ cầu phương
RF	Random Forest	Rừng ngẫu nhiên
RRC	Root-Raised-Cosine	Bộ lọc tạo dạng xung căn cosine nâng
SDR	Software-Defined Radio	Vô tuyến định nghĩa bằng phần mềm
SNR	Signal-to-Noise Ratio	Tỷ số tín hiệu trên nhiễu

Bảng 1: Các từ viết tắt dùng trong báo cáo

DANH SÁCH HÌNH

Hình 1	Chuỗi xử lý và đánh giá của hệ thống DEEPDSP-AMC	8
Hình 2	Kiến trúc CompactIQCNN dùng trong thí nghiệm; tổng cộng 81.030 tham số học được	9
Hình 3	Giao diện DEEPDSP-AMC Workbench khi suy luận trực tiếp một khung 16QAM tại SNR = 3 dB	14
Hình 4	Dạng sóng I/Q của sáu kiểu điều chế sau kênh tại SNR = 6 dB	16
Hình 5	Chòm sao quan sát tại SNR = 18 dB sau hiệu chỉnh CFO thô chỉ để trực quan	17
Hình 6	Mật độ phổ công suất Welch của sáu lớp tại SNR = 9 dB	18
Hình 7	Số khung ở từng tổ hợp lớp và SNR	18
Hình 8	Chiều PCA hai chiều của 18 đặc trưng DSP trên tập test	19
Hình 9	Đường cong loss và validation accuracy của CompactIQCNN	19
Hình 10	Ma trận nhầm lẫn chuẩn hóa của Random Forest trên 18 đặc trưng DSP	21
Hình 11	Ma trận nhầm lẫn chuẩn hóa của CompactIQCNN	22
Hình 12	Ma trận nhầm lẫn chuẩn hóa của mô hình tổ hợp xác suất	23
Hình 13	Độ chính xác của ba phương pháp theo SNR	23
Hình 14	F1-score theo từng kiểu điều chế và phương pháp	24
Hình 15	Độ quan trọng Gini của 18 đặc trưng trong Random Forest	25
Hình 16	Demo một khung 16QAM tại SNR = 3 dB: chòm sao, PSD và xác suất hybrid	26

DANH SÁCH BẢNG

Bảng 1	Các từ viết tắt dùng trong báo cáo	vi
Bảng 2	Ánh xạ nội dung đề án với học phần Thực hành Xử lý tín hiệu số	2
Bảng 3	Cấu hình bộ dữ liệu mô phỏng	8
Bảng 4	Đặc điểm sáu lớp điều chế	9
Bảng 5	Siêu tham số của hai mô hình và phép tổ hợp	10
Bảng 6	Kết quả kiểm tra notebook sau lần chạy phát hành	15
Bảng 7	Kết quả trên 1.320 khung test độc lập	20
Bảng 8	Độ trễ suy luận đo trên máy chạy notebook	25

CHƯƠNG 1

GIỚI THIỆU

1.1. Bối cảnh và lý do chọn đề tài

Nhận dạng điều chế tự động (automatic modulation classification — AMC) là bước xác định kiểu điều chế của tín hiệu đã phát hiện trước khi chọn bộ giải điều chế. Bài toán có ý nghĩa trong máy thu thích nghi, giám sát phổ và vô tuyến nhận thức [1].

Khác với bài toán ảnh, AMC làm việc trực tiếp với chuỗi băng gốc phức. Mỗi mẫu chứa hai thành phần đồng pha và vuông pha; cấu trúc hữu ích có thể nằm ở biên độ, sai phân pha, moment bậc cao hoặc phân bố năng lượng theo tần số.

Các nghiên cứu CNN trên tín hiệu vô tuyến cho thấy đặc trưng có thể được học trực tiếp từ chuỗi I/Q, đặc biệt khi đánh giá được phân rã theo SNR [2], [3]. Tuy vậy, đặc trưng DSP vẫn có giá trị vì dễ giải thích và chạy tốt với dữ liệu vừa phải.

Giáo trình học phần đi từ tín hiệu rời rạc, hệ LTI và tích chập đến DFT/FFT, phân tích phổ, lọc FIR và IIR [4]. Đề tài nối các khối kiến thức đó thành một chuỗi thu vô tuyến có đầu ra định lượng, thay vì dùng ML như một hộp đen tách rời môn học.

1.2. Câu hỏi nghiên cứu

GHI CHÚ KỸ THUẬT Câu hỏi trung tâm

Với khung I/Q dài 256 mẫu, sáu kiểu điều chế và SNR từ -12 dB đến 18 dB, CNN 1-D trên biểu diễn tuần tự DSP có cải thiện macro-F1 so với Random Forest dùng 18 đặc trưng DSP hay không; và tổ hợp xác suất của hai mô hình đạt mốc 90% accuracy từ mức SNR nào?

Câu hỏi được giới hạn trong mô phỏng có kiểm soát. Kết quả không được suy rộng thành hiệu năng của một máy thu SDR thực nếu chưa có dữ liệu thu qua phần cứng.

1.3. Mục tiêu

Đề án đặt ra năm mục tiêu có thể kiểm tra:

- Xây dựng bộ sinh BPSK, QPSK, 8PSK, 16QAM, 2FSK và 4FSK ở dạng I/Q.
- Mô phỏng RRC, AWGN, lệch pha, CFO, dịch thời gian và đa đường nhẹ.

- Thiết kế baseline Random Forest với đặc trưng DSP có ý nghĩa vật lý.
- Huấn luyện CNN 1-D gọn nhẹ và chọn hệ số fusion chỉ trên validation.
- Đánh giá bằng accuracy, macro-F1, ma trận nhầm lẫn, đường cong theo SNR và độ trễ cục bộ.

1.4. Liên hệ với nội dung học phần

Khối kiến thức	Nội dung trong giáo trình/ lab	Cách dùng trong đồ án
Tín hiệu rời rạc	Tạo và biểu diễn chuỗi mẫu	Khung I/Q phức dài 256 mẫu
Hệ LTI	Phương trình sai phân, tích chập	Tạo dạng RRC và kênh đa đường
DFT/FFT	Phổ biên độ, pha, định lý tích chập	PSD, entropy phổ, centroid và spread
FIR	Thiết kế bằng cửa sổ và đáp ứng tần số	Bộ lọc RRC hữu hạn
Đánh giá số	Vẽ đồ thị và kiểm nghiệm bằng Python	SNR curve, confusion matrix, latency

Bảng 2: Ánh xạ nội dung đồ án với học phần Thực hành Xử lý tín hiệu số

Notebook của lớp dùng NumPy, SciPy và Matplotlib để triển khai các phép tính trên [5]. Đồ án giữ cùng hệ sinh thái, bổ sung scikit-learn và PyTorch cho phần ML/DL.

1.5. Phạm vi và giả thiết

Dữ liệu gồm 6.600 khung cân bằng, 11 mức SNR cách nhau 3 dB. Công suất mỗi khung được chuẩn hóa trước khi đưa vào bộ phân loại; SNR không phải là đặc trưng đầu vào.

Kênh có một tia chính và một echo yếu, CFO tối đa 0,002 chu kỳ/mẫu, pha ban đầu ngẫu nhiên và AWGN. Không mô phỏng Doppler nhanh, nhiễu xung, nhiễu đồng kênh, lệch tốc độ lấy mẫu hoặc bộ khuếch đại phi tuyến.

1.6. Đóng góp thực hiện

Đóng góp của đồ án nằm ở việc tích hợp và kiểm chứng, không tuyên bố thuật toán AMC mới:

- notebook tự chứa, sinh dữ liệu cục bộ và chạy lại bằng hạt giống 22207056;
- so sánh công bằng hai họ mô hình trên cùng split và cùng tập test;
- fusion được chọn trên validation, tránh tối ưu theo test;

- 13 hình kết quả được tạo trực tiếp từ lần chạy đã lưu;
- báo cáo nêu rõ giới hạn giữa mô phỏng và triển khai SDR thực.

1.7. Cấu trúc báo cáo

Chương 2 trình bày mô hình tín hiệu và cơ sở DSP/ML. Chương 3 mô tả thiết kế thí nghiệm. Chương 4 nêu triển khai notebook. Chương 5 phân tích kết quả. Chương 6 kết luận, giới hạn và hướng phát triển.

CHƯƠNG 2

CƠ SỞ LÝ THUYẾT

2.1. Biểu diễn bằng gốc phức

Một khung tín hiệu thu được biểu diễn bởi

$$x[n] = I[n] + jQ[n], \quad n = 0, 1, \dots, N - 1. \quad (1)$$

Trong đó $I[n]$ là thành phần đồng pha, $Q[n]$ là thành phần vuông pha và $j^2 = -1$. Biểu diễn này giữ được cả biên độ lẫn pha tức thời, phù hợp với chuỗi thu của SDR.

Công suất trung bình của khung dài N là

$$P_x = \frac{1}{N} \sum_{n=0}^{N-1} |x[n]|^2. \quad (2)$$

Notebook chuẩn hóa $x[n] \leftarrow \frac{x[n]}{\sqrt{P_x + \varepsilon}}$ trước khi trích đặc trưng. Bước này loại hệ số khuếch đại chung nhưng không loại cấu trúc điều chế.

2.2. Ánh xạ ký hiệu số

Với M -PSK, ký hiệu lý tưởng có biên độ không đổi:

$$a_k = \exp\left(j\left(2\pi\frac{k}{M} + \varphi_{\text{off}}\right)\right), \quad k \in \{0, \dots, M - 1\}. \quad (3)$$

16QAM dùng hai trục mức $I, Q \in \{-3, -1, 1, 3\}$ và chuẩn hóa bởi $\sqrt{10}$:

$$a_{p,q} = \frac{p + jq}{\sqrt{10}}. \quad (4)$$

FSK mã hóa ký hiệu bằng tần số tức thời. Với chuỗi tần số chuẩn hóa $f_{m[n]}$, pha liên tục được tạo bởi

$$\varphi[n] = \varphi[n - 1] + 2\pi f_{m[n]}, \quad x[n] = \exp(j\varphi[n]). \quad (5)$$

Các công thức chòm sao và mô hình kênh băng gốc tuân theo cách trình bày chuẩn của truyền thông số [6].

2.3. Tạo dạng xung RRC và tích chập

PSK/QAM được chèn không theo hệ số $L = 8$ rồi lọc RRC. Với roll-off $\beta = 0,35$, đáp ứng xung liên tục chuẩn hóa là

$$g(t) = \frac{\sin(\pi t(1 - \beta)) + 4\beta t \cos(\pi t(1 + \beta))}{\pi t(1 - (4\beta t)^2)}. \quad (6)$$

Hai điểm suy biến $t = 0$ và $|t| = \frac{1}{4\beta}$ được tính bằng giới hạn giải tích. Vector hệ số sau cùng được chuẩn hóa năng lượng:

$$\sum_n |g[n]|^2 = 1. \quad (7)$$

Phép lọc là tích chập của chuỗi chèn không $u[n]$ với $g[n]$:

$$s[n] = (u * g)[n] = \sum_k u[k]g[n - k]. \quad (8)$$

Đây là ứng dụng trực tiếp của hệ LTI và tích chập đã học trong Bài 2 [4].

2.4. Mô hình kênh

Kênh mô phỏng được viết gọn:

$$r[n] = \exp(j(2\pi\Delta f n + \varphi_0))(s * h)[n - n_0] + w[n]. \quad (9)$$

Δf là CFO, φ_0 là lệch pha, n_0 là dịch thời gian. Đáp ứng $h[n]$ gồm tia chính và một echo yếu trễ 1–4 mẫu. Nhiễu $w[n]$ là Gaussian phức tròn.

Với công suất tín hiệu P_s , công suất nhiễu cho SNR yêu cầu được đặt bởi

$$P_w = P_s 10^{-\frac{\text{SNR}_{\text{dB}}}{10}}. \quad (10)$$

Hai thành phần nhiễu thực và ảo độc lập có phương sai $\frac{P_w}{2}$. Nhờ vậy tổng công suất nhiễu phức bằng P_w .

2.5. Phân tích Fourier và mật độ phổ công suất

DFT của khung dài N là

$$X[k] = \sum_{n=0}^{N-1} x[n] \exp\left(-j2\pi k \frac{n}{N}\right). \quad (11)$$

Nhân cửa sổ Hann trước FFT giảm rò phổ do quan sát hữu hạn; đánh đổi giữa độ rộng búp chính và búp phụ cần được hiểu đúng [7].

Đồ án dùng phương pháp Welch để vẽ PSD. Tín hiệu được chia thành các đoạn chồng lấn, tính periodogram có cửa sổ rồi lấy trung bình [8]:

$$\hat{S}_{xx}[k] = \frac{1}{L} \sum_{l=1}^L \frac{1}{NU} \left| \text{DFT}(w[n]x_{l[n]}) \right|^2. \quad (12)$$

PSD dùng để diễn giải khác biệt giữa FSK và PSK/QAM, đồng thời tạo entropy, centroid và spread phổ.

2.6. Đặc trưng DSP

PAPR đo độ đỉnh của bao tín hiệu:

$$\text{PAPR} = \max_n \frac{|x[n]|^2}{\frac{1}{N} \sum_n |x[n]|^2}. \quad (13)$$

Moment phức tổng quát được định nghĩa

$$M_{p,q} = E\{x^{p-q}(x^*)^q\}. \quad (14)$$

Notebook dùng độ lớn của $E\{x^2\}$, $E\{x^4\}$ và $E\{x^6\}$ như các dấu vết bất biến tương đối với pha. Độ tập trung sai phân pha là

$$R_{\Delta\varphi} = \left| \frac{1}{N-1} \sum_{n=1}^{N-1} \exp(j\Delta\varphi[n]) \right|. \quad (15)$$

Với phổ công suất chuẩn hóa p_k , entropy phổ là

$$H_s = -\frac{1}{\log_2 N} \sum_{k=0}^{N-1} p_k \log_2(p_k + \varepsilon). \quad (16)$$

Giá trị gần 1 biểu thị năng lượng dàn đều; giá trị thấp cho thấy năng lượng tập trung. Tổng cộng 18 đặc trưng được đưa vào Random Forest.

2.7. Random Forest

Random Forest là tổ hợp nhiều cây quyết định huấn luyện trên các mẫu bootstrap và tập con đặc trưng ngẫu nhiên [9]. Xác suất lớp được lấy trung bình từ T cây:

$$\hat{p}_{\text{RF}(c|x)} = \frac{1}{T} \sum_{t=1}^T p_{t(c|x)}. \quad (17)$$

Ưu điểm trong đồ án là huấn luyện nhanh, xử lý quan hệ phi tuyến và cung cấp feature importance. Nhược điểm là phụ thuộc chất lượng đặc trưng thủ công.

2.8. CNN 1-D và tổ hợp xác suất

Một lớp tích chập 1-D tính

$$y_{k[n]} = \sigma \left(b_k + \sum_c \sum_{m=0}^{M-1} w_{k,c}[m] x_{c[n-m]} \right). \quad (18)$$

Đầu ra cuối dùng softmax:

$$p(c|x) = \frac{\exp(z_c)}{\sum_{j=1}^C \exp(z_j)}. \quad (19)$$

CNN được huấn luyện bằng cross-entropy có label smoothing nhỏ. PyTorch cung cấp tensor, tự động vi phân và các kernel tối ưu cho chuỗi huấn luyện [10].

Hai vector xác suất được tổ hợp:

$$p_{\text{hybrid}} = \alpha p_{\text{CNN}} + (1 - \alpha) p_{\text{RF}}. \quad (20)$$

α được quét trên validation và cố định trước test. Đây là ranh giới quan trọng để không dùng tập test như một tham số huấn luyện.

2.9. Chỉ số đánh giá

Accuracy đo tỷ lệ dự đoán đúng toàn bộ:

$$\text{Accuracy} = \frac{\sum_c \text{TP}_c}{N}. \quad (21)$$

Với lớp c , precision và recall là

$$\text{Precision}_c = \frac{\text{TP}_c}{\text{TP}_c + \text{FP}_c}, \quad \text{Recall}_c = \frac{\text{TP}_c}{\text{TP}_c + \text{FN}_c}. \quad (22)$$


$$\text{F1}_c = 2P_c \frac{R_c}{P_c + R_c} \quad (23)$$

và macro-F1 là trung bình không trọng số trên sáu lớp. Dù dữ liệu cân bằng, macro-F1 vẫn hữu ích để phát hiện lớp yếu.

CHƯƠNG 3

THIẾT KẾ THÍ NGHIỆM

3.1. Kiến trúc tổng thể



Hình 1: Chuỗi xử lý và đánh giá của hệ thống DEEPDSP-AMC

Chuỗi ở **Hình 1** tách rõ phân vật lý tín hiệu, biểu diễn đặc trưng, mô hình phân loại và đánh giá. Mỗi kết quả cuối đều truy được về một cell notebook và một tệp hình trong thư mục `assets/figures`.

3.2. Thiết kế dữ liệu

Thành phần	Giá trị	Lý do
Lớp	6	Bao phủ PSK, QAM và FSK với mức phân biệt tăng dần
SNR	-12:3:18 dB	Quan sát từ vùng nhiễu mạnh đến vùng ổn định
Khung mỗi lớp-SNR	100	Dữ liệu cân bằng và thời gian chạy phù hợp CPU
Độ dài khung	256 mẫu	Đủ 32 ký hiệu ở 8 mẫu/ký hiệu
RRC	$\beta = 0, 35$; span 8	Giới hạn băng thông cho PSK/QAM
CFO	$ \Delta f \leq 0,002$	Mô phỏng sai lệch dao động cục bộ nhẹ
Echo	0–0,20	Đa đường nhẹ, trễ 1–4 mẫu
Hạt giống	22207056	Tái lập đúng lần chạy

Bảng 3: Cấu hình bộ dữ liệu mô phỏng

Mỗi khung được sinh độc lập từ chuỗi ký hiệu mới. Không dùng cửa sổ trượt trên một bản ghi dài; do đó các tập không chia sẻ đoạn tín hiệu gần trùng nhau.

Thiết kế tham khảo cách tổ chức dữ liệu tín hiệu tổng hợp và suy giảm kênh trong TorchSig [11], nhưng bộ sinh của đề án được viết riêng, tối giản cho phạm vi học phân và không sao chép mã nguồn.

3.3. Các lớp điều chế

Lớp	Họ	Số trạng thái	Dấu vết DSP chính
BPSK	PSK	2 pha	Moment chẵn và sai phân pha
QPSK	PSK	4 pha	Pha bốn cụm sau đồng bộ
8PSK	PSK	8 pha	Để nhầm QPSK ở SNR thấp
16QAM	QAM	16 điểm	Bao biên độ đa mức, PAPR cao hơn PSK
2FSK	FSK	2 tần số	Hai vùng năng lượng phổ
4FSK	FSK	4 tần số	Phổ rộng và nhiều trạng thái tần số

Bảng 4: Đặc điểm sáu lớp điều chế

3.4. Chia dữ liệu và chống rò rỉ

Chỉ số mẫu được chia theo nhãn ghép (`cclass`, `SNR`): 80% cho train+validation và 20% cho test. Phần train+validation được tách tiếp 15% làm validation.


Kết quả là 4.488 khung train, 792 validation và 1.320 test. Ba tập rời nhau theo chỉ số; phân bố lớp–SNR được giữ đồng đều.

SNR không xuất hiện trong vector 18 đặc trưng hay tensor CNN. Nó chỉ được dùng khi sinh nhiễu, phân tầng split và vẽ đường cong đánh giá.

3.5. Hai nhánh biểu diễn

Nhánh RF tạo vector 18 chiều. Ngoài các moment, PAPR và entropy, vector còn có skewness/kurtosis bao, tỷ lệ đổi dấu I/Q, spectral flatness, centroid và spread.

Nhánh CNN tạo tensor 4×256 : I, Q, $|x|$ và $\sin(\Delta\varphi)$. Kênh sai phân pha giảm nhạy với pha khởi tạo, trong khi I/Q giữ quỹ đạo phức.



Hình 2: Kiến trúc CompactIQCNN dùng trong thí nghiệm; tổng cộng 81.030 tham số học được

CompactIQCNN ở Hình 2 có ba mức kênh 32, 64 và 96, hai lần max-pooling, global average pooling và lớp phân loại sáu đầu ra. Mạng có 81.030 tham số, đủ nhỏ để huấn luyện CPU trong notebook.

3.6. Siêu tham số

Hạng mục	Giá trị	Ghi chú
Random Forest	400 cây	min_samples_leaf=2; max_features=sqrt
Optimizer	AdamW	learning rate $1,5 \times 10^{-3}$; weight decay 10^{-4}
Batch	256	Giữ thời gian CPU ngắn
Epoch tối đa	22	Early stopping patience 5
Loss	Cross-entropy	Label smoothing 0,03
Fusion	$\alpha \in \{0; 0,05; \dots; 1\}$	Chọn macro-F1 cao nhất trên validation

Bảng 5: Siêu tham số của hai mô hình và phép tổ hợp

3.7. Quy trình đánh giá

Sau khi khóa mô hình, notebook tính accuracy và macro-F1 trên test. Ma trận nhầm lẫn được chuẩn hóa theo hàng để mỗi ô biểu thị tỷ lệ trong lớp thật.

Đường cong accuracy–SNR được tính từ các tập con test tương ứng. Mỗi điểm có 120 khung: 20 khung cho mỗi lớp tại một mức SNR.

Khoảng tin cậy 95% cho accuracy tổng thể dùng công thức Wilson. Độ trễ CNN được đo sau warm-up, batch 256 và 30 lần lặp; số đo RF loại trừ thời gian trích đặc trưng nên phải được chú thích đúng.

CHƯƠNG 4

TRIỂN KHAI NOTEBOOK VÀ ỨNG DỤNG DEMO

4.1. Môi trường phần mềm

Notebook được chạy trên Windows 11, Python 3.14.3 và CPU. Các thư viện khoa học là NumPy 2.4.4, SciPy 1.17.1, scikit-learn 1.9.0, Matplotlib 3.10.9 và PyTorch 2.11.0+cpu.

SciPy cung cấp FFT, xử lý tín hiệu và thống kê số [12]. Random Forest dùng API scikit-learn [13]. CNN được cài bằng lớp `torch.nn.Module` [10].

GHI CHÚ KỸ THUẬT Quy ước trình bày thuật toán

Chương này dùng mã giả độc lập ngôn ngữ để làm rõ dữ liệu vào, dữ liệu ra, nhánh xử lý và điều kiện chống rò rỉ. Mã Python tương ứng được chuyển nguyên vẹn xuống Phụ lục A; notebook nộp kèm vẫn là nguồn thực thi đầy đủ.

4.2. Tạo xung RRC

Thuật toán 1 hiện thực ba miền của đáp ứng RRC ở [Phương trình 6](#). Hai điểm suy biến được thay bằng giới hạn giải tích; bước cuối áp đặt bất biến năng lượng ở [Phương trình 7](#). Mã Python tương ứng nằm tại [Mã nguồn 1](#).

Đầu vào: $\beta \in (0, 1]$: roll-off; L : số mẫu trên ký hiệu; S : độ dài theo ký hiệu
Đầu ra: Vector $g[0..SL]$ thỏa $\sum_n |g[n]|^2 = 1$

```
1 Đặt  $N \leftarrow SL$  và  $t_n \leftarrow \frac{n-\frac{N}{2}}{L}$ , với  $n = 0, 1, \dots, N$ .
2 for mỗi  $n$  do
3   if  $|t_n| < \varepsilon$  then
4      $g[n] \leftarrow 1 + \beta(\frac{4}{\pi} - 1)$ .
5   else if  $||t_n| - \frac{1}{4\beta}| < \varepsilon$  then
6     Gán  $g[n]$  bằng giới hạn giải tích của RRC tại  $|t_n| = \frac{1}{4\beta}$ .
7   else
8     Đánh giá trực tiếp biểu thức RRC ở Phương trình 6 tại  $t = t_n$ .
9   end if
10 end for
11 Chuẩn hóa  $g \leftarrow \frac{g}{\sqrt{\sum_n |g[n]|^2}}$ .
12 return  $g$ .
```

Thuật toán 1: Sinh bộ hệ số RRC có năng lượng đơn vị

4.3. Mô phỏng AWGN theo công suất đo

Công suất nhiễu được suy ra từ công suất của tín hiệu sau kênh. Cách này không ngầm giả sử công suất đầu vào bằng một và giữ đúng quan hệ ở [Phương trình 10](#). Mã triển khai nằm tại [Mã nguồn 2](#).

Đầu vào: Khung sạch $x[0..N-1]$ sau kênh và mức γ tính bằng dB
Đầu ra: Khung thu r đã chuẩn hóa công suất

- 1 Tính $P_s \leftarrow \frac{1}{N} \sum_n |x[n]|^2$.
- 2 Đặt $P_w \leftarrow P_s 10^{-\frac{\gamma}{10}}$.
- 3 Sinh $u[n], v[n]$ độc lập theo $\mathcal{N}(0, 1)$.
- 4 Tạo $w[n] \leftarrow \sqrt{\frac{P_w}{2}}(u[n] + jv[n])$.
- 5 Cộng nhiễu: $r[n] \leftarrow x[n] + w[n]$.
- 6 Chuẩn hóa $r \leftarrow \frac{r}{\sqrt{\frac{1}{N} \sum_n |r[n]|^2 + \epsilon}}$.
- 7 **return** r .

Thuật toán 2: Chèn AWGN phức theo SNR yêu cầu

4.4. Trích đặc trưng DSP

Nhánh cổ điển ánh xạ mỗi khung phức thành 18 đại lượng vô hướng. SNR không xuất hiện trong vector đặc trưng. Cửa sổ Hann giảm rò phổ trước FFT; phổ công suất chuẩn hóa được xem như một phân bố rời rạc để tính entropy, centroid và spread. Mã tính nhóm đặc trưng phổ nằm tại [Mã nguồn 3](#).

Đầu vào: Khung phức $z[0..N-1]$
Đầu ra: Vector đặc trưng $f \in \mathbb{R}^{18}$ không chứa nhân và SNR

- 1 Loại DC và chuẩn hóa RMS của z .
- 2 Tính thống kê biên độ: mean, độ lệch chuẩn, skewness, kurtosis và PAPR.
- 3 Tính moment phức và độ tập trung sai phân pha.
- 4 Đặt $z_w[n] \leftarrow z[n] w_{\text{Hann}}[n]$.
- 5 Tính $S[k] \leftarrow |\text{FFTshift}(\text{FFT}(z_w)) [k]|^2$.
- 6 Chuẩn hóa $p[k] \leftarrow \frac{S[k]}{\sum_j S[j] + \epsilon}$.
- 7 Tính centroid, spread và entropy phổ từ $p[k]$.
- 8 Ghép các nhóm thời gian, moment, pha và phổ theo thứ tự cố định.
- 9 Kiểm tra $\dim(f) = 18$ và mọi phần tử của f là hữu hạn.
- 10 **return** f .

Thuật toán 3: Trích vector đặc trưng DSP từ một khung I/Q

4.5. Tạo tensor CNN

Mỗi khung được đổi thành tensor bốn kênh $[I, Q, |x|, \sin(\Delta\varphi)]$. Hàm sin làm liên tục biểu diễn sai phân pha qua biên $-\pi$ và π ; tensor không chứa SNR. Mã Python tương ứng nằm tại [Mã nguồn 4](#).

Đầu vào: Ma trận khung phức $X \in \mathbb{C}^{B \times N}$
Đầu ra: Tensor thực $T \in \mathbb{R}^{B \times 4 \times N}$

```
1 Chuẩn hóa từng khung:  $Z_b \leftarrow \frac{X_b}{\sqrt{\text{mean}(|X_b|^2) + \epsilon}}$ .  
2 for  $n = 1, 2, \dots, N - 1$  do  
3    $\Delta\varphi_{b[n]} \leftarrow \angle(Z_{b[n]} Z_b^*[n - 1])$ .  
4 end for  
5 Sao chép giá trị biên để bổ sung  $\Delta\varphi_{b[0]}$ .  
6 Xếp kênh  $T_b \leftarrow [\Re(Z_b), \Im(Z_b), |Z_b|, \sin(\Delta\varphi_b)]$ .  
7 Ép kiểu số thực 32 bit và kiểm tra kích thước  $B \times 4 \times N$ .  
8 return  $T$ .
```

Thuật toán 4: Tạo tensor bốn kênh cho CompactIQCNN

4.6. Chọn hệ số fusion

Hệ số α chỉ được chọn trên validation. Tập test không tham gia tìm siêu tham số; đây là điều kiện cần để kết quả hybrid không bị lạc quan. Mã triển khai nằm tại [Mã nguồn 5](#).

Đầu vào: Xác suất RF/CNN trên validation và test; nhãn y_{val} ; lưới $\mathcal{A}$
Đầu ra: Trọng số α^* và xác suất hybrid trên test

```
1 Khởi tạo ánh xạ điểm  $J : \mathcal{A} \rightarrow \mathbb{R}$ .  
2 for mỗi  $\alpha \in \mathcal{A}$  do  
3    $p_{\text{val}}^\alpha \leftarrow \alpha p_{\text{CNN, val}} + (1 - \alpha) p_{\text{RF, val}}$ .  
4    $J(\alpha) \leftarrow \text{macro-F1}(y_{\text{val}}, \arg \max_c p_{\text{val}}^\alpha(c))$ .  
5 end for  
6 Khóa  $\alpha^* \leftarrow \arg \max_{\alpha \in \mathcal{A}} J(\alpha)$ .  
7  $p_{\text{test}} \leftarrow \alpha^* p_{\text{CNN, test}} + (1 - \alpha^*) p_{\text{RF, test}}$ .  
8 return  $(\alpha^*, p_{\text{test}})$ .
```

Thuật toán 5: Chọn trọng số tổ hợp xác suất mà không dùng tập test


4.7. Suy luận tương tác trên ứng dụng demo

Ứng dụng demo không đọc một dự đoán đã lưu. Mỗi lần bấm nút, nó sinh lại khung I/Q từ seed, áp kênh theo các tham số đang hiển thị, gọi đúng pipeline RF và checkpoint CNN của notebook, rồi mới dựng bốn đồ thị. Cơ chế này cho phép đối chiếu nhãn phát với nhãn dự đoán và lặp lại chính xác một phép thử. Mã điều phối tương ứng nằm tại [Mã nguồn 6](#).

Đầu vào: Lớp phát c ; SNR γ ; seed s ; biên echo η_h ; biên CFO η_f ; mô hình đã khóa M_R, M_C
Đầu ra: Dự đoán $\hat{c}$; xác suất p_R, p_C, p_H ; đồ thị $\mathcal{V}$; nhật ký $\mathcal{L}$

- 1 Khởi tạo bộ sinh số giả ngẫu nhiên $\mathcal{R} \leftarrow \text{PRNG}(s)$.
- 2 Sinh khung sạch x thuộc lớp c ; tạo dạng xung RRC với $L = 8$.
- 3 Rút kênh hai tia, pha đầu, dịch thời gian và CFO trong các biên η_h, η_f .
- 4 Đo công suất sau kênh và cộng AWGN để đạt γ dB.
- 5 Tính $f \leftarrow \text{DSP18}(r)$ và $T \leftarrow \text{IQTensor4}(r)$.
- 6 $p_R \leftarrow M_R.\text{predict_proba}(f)$; $p_C \leftarrow \text{softmax}(M_C(T))$.
- 7 $p_H \leftarrow \alpha^* p_C + (1 - \alpha^*) p_R$, với $\alpha^* = 0.55$.
- 8 $\hat{c} \leftarrow \arg \max_k p_{H[k]}$; $q \leftarrow \max_k p_{H[k]}$.
- 9 Kiểm tra $\sum_k p_{R[k]} \approx \sum_k p_{C[k]} \approx \sum_k p_{H[k]} \approx 1$ và mọi giá trị hữu hạn.
- 10 Dựng $\mathcal{V}$ gồm I/Q, chòm sao, PSD và ba vector xác suất; ghi seed, hệ số kênh, độ trễ vào $\mathcal{L}$.
- 11 **return** $(\hat{c}, q, p_R, p_C, p_H, \mathcal{V}, \mathcal{L})$.

Thuật toán 6: Suy luận một khung và tạo hồ sơ bằng chứng cho giao diện



Hình 3: Giao diện DEEPDSP-AMC Workbench khi suy luận trực tiếp một khung 16QAM tại SNR = 3 dB

Hình 3 tổ chức màn hình theo hai miền: miền điều khiển khóa đầu vào phép thử và miền bằng chứng hiển thị nhãn, confidence, I/Q, chòm sao, PSD cùng xác suất RF–CNN–

hybrid. Nhặt ký trong ba tab cuối lưu hệ số kênh thực tế và thời gian từng công đoạn; nút quét sáu lớp chỉ là phép kiểm tra minh họa, không thay thế đánh giá trên 1.320 khung test.

VIDEO DEMO TRỰC TUYẾN

DEEPDSP-AMC — trình bày notebook, kết quả và ứng dụng tương tác



Video dài 4 phút 50 giây, ghi lại quy trình xử lý tín hiệu và một lượt suy luận trực tiếp trên Workbench. Quét mã QR hoặc nhấn vào đường dẫn dưới đây.

[Mở video demo trên YouTube](#)

youtu.be/yl5Sk6plWXg

4.8. Kiểm tra tự động

Notebook dùng bằng `assert` nếu dữ liệu chứa NaN/Inf, công suất chuẩn hóa sai, ba split giao nhau hoặc thiếu đầu ra. Notebook đã lưu có 33 cell; toàn bộ 22 cell code đều đã chạy và không có output lỗi. Ứng dụng được kiểm tra thêm bằng Streamlit AppTest và một trình duyệt thật: bốn nút, bốn biểu đồ, ba tab, suy luận đơn và quét sáu lớp đều hoạt động, không có exception hay lỗi console.

Chỉ tiêu	Giá trị	Chỉ tiêu	Giá trị
Tổng số cell	33	Code cell đã chạy	22/22
Output lỗi	0	Ảnh PNG nhúng	13
Tệp bắt buộc khác rỗng	18/18	Giao train/validation/test	0 mẫu

Bảng 6: Kết quả kiểm tra notebook sau lần chạy phát hành


4.9. Đầu ra máy tạo

Notebook lưu `metrics.json`, lịch sử huấn luyện, dự đoán test, trọng số CNN, pipeline RF và 13 hình. Báo cáo chỉ dùng các số liệu có trong `metrics.json` của lần chạy cuối.

CHƯƠNG 5


KẾT QUẢ VÀ THẢO LUẬN

5.1. Kiểm tra tín hiệu mô phỏng




Hình 4: Dạng sóng I/Q của sáu kiểu điều chế sau kênh tại SNR = 6 dB

Hình 4 cho thấy PSK/QAM sau RRC có bao biến thiên do quá trình chuyển ký hiệu, trong khi FSK giữ bao gần hằng. Nhiễu và echo làm hai thành phần I/Q không còn quỹ đạo lý tưởng.




Hình 5: Chòm sao quan sát tại SNR = 18 dB sau hiệu chỉnh CFO thô chỉ để trực quan

Chòm sao ở [Hình 5](#) không dùng đồng bộ ký hiệu hoàn chỉnh. Độ xoay còn lại và các điểm chuyển tiếp RRC giải thích vì sao hình không thành các cụm sắc như sơ đồ lý tưởng.



Hình 6: Mật độ phổ công suất Welch của sáu lớp tại SNR = 9 dB


PSD phân biệt rõ hai họ. PSK/QAM tập trung quanh tần số mang bằng gốc; FSK tạo nhiều vùng năng lượng theo các tần số trạng thái. 4FSK có độ trải phổ lớn hơn 2FSK.



Hình 7: Số khung ở từng tổ hợp lớp và SNR

Mọi ô trong [Hình 7](#) có đúng 100 khung. Vì vậy accuracy tổng thể không bị một lớp hoặc mức SNR chiếm ưu thế về số lượng.


5.2. Không gian đặc trưng DSP



Hình 8: Chiều PCA hai chiều của 18 đặc trưng DSP trên tập test

PCA chỉ là phép chiếu tuyến tính để quan sát, không phải đầu vào RF. Hai họ FSK tách tốt hơn, còn QPSK/8PSK/16QAM chồng lấn khi SNR thấp và có pha/CFO ngẫu nhiên.

5.3. Quá trình huấn luyện CNN



Hình 9: Đường cong loss và validation accuracy của CompactIQCNN

CNN chạy 19 epoch trước khi early stopping, mất 34,98 s trên CPU. Khoảng cách train-validation loss không tăng liên tục ở cuối, cho thấy early stopping đã dừng trước khi xu hướng overfit kéo dài.

5.4. Kết quả tổng thể

0,5817	0,7201	0,7340
RF macro-F1	CNN macro-F1	Hybrid macro-F1
58,48%	71,82%	73,48%

Mô hình	Accuracy	Macro-F1	Thời gian train
RF-DSP	58,48%	0,5817	0,76 s
CNN-DSP	71,82%	0,7201	34,98 s
Hybrid	73,48%	0,7340	Không train riêng


Bảng 7: Kết quả trên 1.320 khung test độc lập

CNN tăng 0,1384 macro-F1 so với RF. Hybrid tăng thêm 0,0139 so với CNN và 0,1523 so với RF. Hệ số $\alpha = 0,55$ được chọn trên validation, nên mức tăng hybrid không đến từ việc dò test.

GIỚI HẠN Diễn giải đúng phạm vi


Hybrid tốt nhất trong cấu hình mô phỏng này. Sự khác biệt chưa được kiểm định qua nhiều lần huấn luyện độc lập và chưa chứng minh ưu thế trên dữ liệu SDR thật.

5.5. Ma trận nhầm lẫn




Hình 10: Ma trận nhầm lẫn chuẩn hóa của Random Forest trên 18 đặc trưng DSP

RF nhận biết FSK tốt hơn nhóm PSK/QAM. Nhầm lẫn giữa QPSK và 8PSK phù hợp với việc các chòm sao có các điểm dùng chung và bị phá vỡ bởi noise, CFO, pha ngẫu nhiên [2].



Hình 11: Ma trận nhầm lẫn chuẩn hóa của CompactIQCNN


CNN giảm nhiều phần tử ngoài đường chéo so với RF, đặc biệt khi cần kết hợp mẫu hình cục bộ theo thời gian. Kết quả ủng hộ việc dùng biểu diễn tuần tự thay vì chỉ thống kê toàn khung.



Hình 12: Ma trận nhầm lẫn chuẩn hóa của mô hình tổ hợp xác suất

Hybrid giữ ưu điểm của CNN nhưng tận dụng xác suất RF ở các mẫu có dấu vết phổ/moment rõ. Không có luật thủ công theo lớp; hai vector xác suất được trộn cùng hệ số.

5.6. Ảnh hưởng của SNR




Hình 13: Độ chính xác của ba phương pháp theo SNR

Tại -12 dB, hybrid chỉ đạt 28,33%; thông tin điều chế bị nhiễu che lấp đáng kể. Đường cong tăng theo SNR và hybrid đạt đúng 90% ở 9 dB, sau đó tiến đến 93,33% tại 15–18 dB.

Không nên chỉ báo một accuracy tổng thể vì nó trộn các vùng SNR khác nhau. Phân rã như [Hình 13](#) giúp xác định vùng hoạt động thay vì che mất điểm gãy của hệ thống [2].


5.7. Hiệu năng theo lớp



Hình 14: F1-score theo từng kiểu điều chế và phương pháp

F1 theo lớp cho thấy độ khó không đồng đều. Các lớp FSK được hỗ trợ mạnh bởi cấu trúc tần số; PSK bậc cao chịu ảnh hưởng nhiều hơn từ noise và sai lệch pha.

5.8. Độ quan trọng đặc trưng



Hình 15: Độ quan trọng Gini của 18 đặc trưng trong Random Forest


Feature importance là mức giảm impurity trung bình, không phải quan hệ nhân quả. Các đặc trưng tương quan có thể chia sẻ độ quan trọng; vì vậy biểu đồ dùng để giải thích xu hướng, không dùng để khẳng định một đại lượng là nguyên nhân duy nhất.

5.9. Độ trễ cục bộ và demo

Nhánh	ms/khung	Điều kiện đo
RF–DSP	0,1963 ms/khung	Batch 256; không gồm thời gian trích 18 đặc trưng
CNN–DSP	0,0626 ms/khung	CPU; batch 256; warm-up 5; 30 lần lặp

Bảng 8: Độ trễ suy luận đo trên máy chạy notebook

CNN nhanh hơn ở phần suy luận đã đo, nhưng so sánh chưa hoàn toàn đối xứng vì RF cần thêm bước trích đặc trưng. Các số này không đại diện cho vi điều khiển, FPGA hoặc pipeline SDR thời gian thực.



Hình 16: Demo một khung 16QAM tại SNR = 3 dB: chòm sao, PSD và xác suất hybrid

Hình 16 gom ba góc nhìn cần thiết cho video: tín hiệu quan sát, dấu vết phổ và quyết định xác suất. Người xem có thể thay `demo_kind` và `demo_snr` trong notebook để tạo tình huống khác.

5.10. Trả lời câu hỏi nghiên cứu

KẾT QUẢ Kết luận từ dữ liệu

Trong cấu hình đã khóa, CNN-DSP cải thiện macro-F1 từ 0,5817 lên 0,7201. Tổ hợp xác suất đạt 0,7340 và mốc 90% accuracy từ 9 dB. Vì vậy hai nhánh có tính bổ sung trên dữ liệu mô phỏng đã nêu.

CHƯƠNG 6

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

6.1. Kết quả đạt được

Đồ án đã hoàn thiện chuỗi AMC từ mô hình tín hiệu đến demo. Bộ dữ liệu 6.600 khung bao phủ sáu lớp và 11 mức SNR; mỗi khung đi qua RRC, đa đường nhẹ, CFO, lệch pha và AWGN.

Nhánh RF–DSP dùng 18 đặc trưng giải thích được. Nhánh CNN–DSP dùng tensor bốn kênh và mạng 81.030 tham số. Split theo lớp–SNR giữ cân bằng và không đưa SNR vào đầu vào.

Trên tập test, RF đạt macro-F1 0,5817 CNN đạt 0,7201 hybrid đạt 0,7340. Đường cong theo SNR cho thấy hybrid đạt 90% accuracy từ 9 dB.

Notebook, hình, số liệu và bản mô tả cùng xuất phát từ một lần chạy. Đây là điểm quan trọng hơn việc chỉ trình bày sơ đồ mô hình mà không có đầu ra kiểm chứng.

6.2. Hạn chế

Thứ nhất, dữ liệu được sinh mô phỏng. Mô hình chưa gặp nhiễu phân cực, DC offset, IQ imbalance, clipping, fading nhanh hoặc nhiễu đồng kênh.

Thứ hai, thí nghiệm chỉ dùng một hạt giống huấn luyện. Accuracy và macro-F1 chưa có phân bố qua nhiều seed; khoảng Wilson chỉ phản ánh lấy mẫu test cho accuracy, không phản ánh biến thiên do training.

Thứ ba, split ngẫu nhiên trên dữ liệu mô phỏng chưa kiểm tra domain shift. Một mô hình tốt trên bộ sinh hiện tại có thể học dấu vết riêng của bộ sinh.

Thứ tư, độ trễ được đo theo batch trên CPU. Chưa có chứng cứ về thời gian thực trên SDR, vi điều khiển hay FPGA.

6.3. Hướng phát triển

Hướng ưu tiên là thu dữ liệu I/Q thật bằng RTL-SDR hoặc USRP, tách train/test theo phiên thu và giữ một thiết bị hoặc ngày đo hoàn toàn ngoài huấn luyện.

Có thể bổ sung IQ imbalance, phase noise, lệch tốc độ lấy mẫu, kênh Rayleigh/Rician và nhiễu đồng kênh. Mỗi suy giảm nên có ablation để biết phần nào làm hiệu năng giảm.

Về mô hình, có thể thử complex-valued CNN, mạng residual 1-D, attention nhẹ hoặc knowledge distillation. Mọi cải tiến cần báo cả accuracy–SNR, số tham số và độ trễ.

Về triển khai, pipeline nên chuyển sang streaming: phát hiện tín hiệu, ước lượng tần số mang thô, tạo khung, chuẩn hóa, phân loại và làm trơn quyết định theo thời gian.

6.4. Kết luận cuối

DEEPDSP-AMC đáp ứng mục tiêu một đề án DSP có ML/DL nhưng vẫn giữ bản chất tín hiệu. Kết quả cho thấy việc kết hợp hiểu biết miền với học đặc trưng là hướng phù hợp cho máy thu thông minh ở quy mô thực hành.

Giá trị của đề án nằm ở chuỗi tái lập, số liệu thật và giới hạn được nói rõ. Bước tiếp theo không phải tăng thêm lớp mạng trên cùng dữ liệu, mà là kiểm tra khả năng tổng quát trên tín hiệu vô tuyến đo được.

TÀI LIỆU THAM KHẢO

- [1] O. A. Dobre, A. Abdi, Y. Bar-Ness, và W. Su, “Survey of Automatic Modulation Classification Techniques: Classical Approaches and New Trends”, *IET Communications*, tập 1, số 2, tr 137–156, 2007, doi: [10.1049/iet-com:20050176](https://doi.org/10.1049/iet-com:20050176).
- [2] T. J. O'Shea, J. Corgan, và T. C. Clancy, “Convolutional Radio Modulation Recognition Networks”, trong *Engineering Applications of Neural Networks*, trong Communications in Computer and Information Science, vol. 629. Springer, 2016, tr 213–226. doi: [10.1007/978-3-319-44188-7_16](https://doi.org/10.1007/978-3-319-44188-7_16).
- [3] T. J. O'Shea, T. Roy, và T. C. Clancy, “Over-the-Air Deep Learning Based Radio Signal Classification”, *IEEE Journal of Selected Topics in Signal Processing*, tập 12, số 1, tr 168–179, 2018, doi: [10.1109/JSTSP.2018.2797022](https://doi.org/10.1109/JSTSP.2018.2797022).
- [4] Khoa Điện tử - Viễn thông, Trường Đại học Khoa học Tự nhiên, “Giáo trình Thực hành Xử lý tín hiệu số 2026”. 2026.
- [5] Khoa Điện tử - Viễn thông, Trường Đại học Khoa học Tự nhiên, “Lab Notebooks môn Thực hành Xử lý tín hiệu số”. 2026.
- [6] J. G. Proakis và M. Salehi, *Digital Communications*, 5 a.b. McGraw-Hill, 2008.
- [7] F. J. Harris, “On the Use of Windows for Harmonic Analysis with the Discrete Fourier Transform”, *Proceedings of the IEEE*, tập 66, số 1, tr 51–83, 1978, doi: [10.1109/PROC.1978.10837](https://doi.org/10.1109/PROC.1978.10837).
- [8] P. D. Welch, “The Use of Fast Fourier Transform for the Estimation of Power Spectra: A Method Based on Time Averaging over Short, Modified Periodograms”, *IEEE Transactions on Audio and Electroacoustics*, tập 15, số 2, tr 70–73, 1967, doi: [10.1109/TAU.1967.1161901](https://doi.org/10.1109/TAU.1967.1161901).
- [9] L. Breiman, “Random Forests”, *Machine Learning*, tập 45, tr 5–32, 2001, doi: [10.1023/A:1010933404324](https://doi.org/10.1023/A:1010933404324).
- [10] A. Paszke và c.s., “PyTorch: An Imperative Style, High-Performance Deep Learning Library”, trong *Advances in Neural Information Processing Systems* 32, 2019, tr 8024–8035. [Online]. Có tại: <https://proceedings.neurips.cc/paper/2019/hash/bdbca288fee7f92f2bfa9f7012727740-Abstract.html>
- [11] TorchDSP, “TorchSig: An Open-Source Signal Processing Machine Learning Toolkit”. Truy cập: 16 Tháng Tám 2026. [Online]. Có tại: <https://github.com/TorchDSP/torchsig>
- [12] P. Virtanen, R. Gommers, T. E. Oliphant, và others, “SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python”, *Nature Methods*, tập 17, tr 261–272, 2020, doi: [10.1038/s41592-019-0686-2](https://doi.org/10.1038/s41592-019-0686-2).
- [13] F. Pedregosa, G. Varoquaux, A. Gramfort, và others, “Scikit-learn: Machine Learning in Python”, *Journal of Machine Learning Research*, tập 12, số 85, tr 2825–2830, 2011, [Online]. Có tại: <https://www.jmlr.org/papers/v12/pedregosa11a.html>
- [14] Khoa Điện tử - Viễn thông, Trường Đại học Khoa học Tự nhiên, “Hướng dẫn về khóa luận tốt nghiệp và đồ án (seminar) tốt nghiệp”. Truy cập: 16 Tháng Tám 2026. [Online]. Có tại: <https://fetel.hcmus.edu.vn/quy-dinh-danh-cho-sinh-vien/>
- [15] T. Huynh-The và c.s., “Automatic Modulation Classification: A Deep Architecture Survey”, *IEEE Access*, tập 9, tr 142950–142971, 2021, doi: [10.1109/ACCESS.2021.3120419](https://doi.org/10.1109/ACCESS.2021.3120419).

PHỤ LỤC A — MÃ NGUỒN TRIỂN KHAI CHỌN LỌC

Phụ lục này tập trung các đoạn mã Python đã được mô tả bằng mã giả trong Chương 4. Các listing được trích từ notebook phát hành; notebook `24DTV_DKD2_22207056_LuongHaiLong_SourceCode_AMC.ipynb` là nguồn đầy đủ và có thể thực thi.

A.1. Sinh bộ hệ số RRC

```
1  def rrc_taps(beta, sps, span_symbols):
2      n = np.arange(-span_symbols*sps/2, span_symbols*sps/2 + 1)
3      t = n / sps
4      taps = np.empty_like(t, dtype=float)
5      for i, ti in enumerate(t):
6          if np.isclose(ti, 0.0):
7              taps[i] = 1 + beta * (4/np.pi - 1)
8          elif np.isclose(abs(ti), 1/(4*beta)):
9              taps[i] = (beta/np.sqrt(2)) * (
10                  (1 + 2/np.pi)*np.sin(np.pi/(4*beta))
11                  + (1 - 2/np.pi)*np.cos(np.pi/(4*beta))
12              )
13          else:
14              num = np.sin(np.pi*ti*(1-beta))
15              num += 4*beta*ti*np.cos(np.pi*ti*(1+beta))
16              taps[i] = num / (np.pi*ti*(1-(4*beta*ti)**2))
17      return taps / np.sqrt(np.sum(taps**2))
```

Mã nguồn 1: Hàm tạo bộ lọc RRC và xử lý hai điểm suy biến giải tích

A.2. Chèn AWGN theo công suất đo

```
1 signal_power = float(np.mean(np.abs(shifted) ** 2))
2 noise_power = signal_power / (10.0 ** (snr_db / 10.0))
3 noise = np.sqrt(noise_power / 2.0) * (
4     rng.standard_normal(len(clean))
5     + 1j * rng.standard_normal(len(clean))
6 )
7 received = shifted + noise
8 received /= np.sqrt(np.mean(np.abs(received) ** 2) + 1e-12)
```

 Python

Mã nguồn 2: Đặt công suất AWGN phức từ SNR và chuẩn hóa khung thu

A.3. Nhóm đặc trưng phổ

```
1 windowed = z * signal.windows.hann(len(z), sym=False)
2 spectrum = np.abs(np.fft.fftshift(np.fft.fft(windowed))) ** 2
3 p = spectrum / (np.sum(spectrum) + 1e-12)
4 freq = np.fft.fftshift(np.fft.fftfreq(len(z)))
5 centroid = float(np.sum(freq * p))
6 spread = float(np.sqrt(np.sum(((freq-centroid)**2) * p)))
7 spectral_entropy = -np.sum(p*np.log2(p+1e-12)) / np.log2(len(p))
```

 Python

Mã nguồn 3: Trích centroid, spread và entropy từ phổ công suất đã chuẩn hóa

A.4. Tạo tensor bốn kênh


```
1 def cnn_tensor(x_complex):
2     z = x_complex / np.sqrt(
3         np.mean(np.abs(x_complex)**2, axis=1, keepdims=True) + 1e-12
4     )
5     dphase = np.angle(z[:, 1:] * np.conj(z[:, :-1]))
6     dphase = np.pad(dphase, ((0, 0), (1, 0)), mode="edge")
7     return np.stack(
8         [z.real, z.imag, np.abs(z), np.sin(dphase)], axis=1
9     ).astype(np.float32)
```

 Python

Mã nguồn 4: Chuyển khung I/Q sang biểu diễn I–Q–biên độ–sai phân pha

A.5. Chọn hệ số fusion

```
1 alpha_grid = np.linspace(0.0, 1.0, 21)
2 scores = []
3 for alpha in alpha_grid:
4     val_prob = alpha*cnn_val_prob + (1-alpha)*rf_val_prob
5     scores.append(f1_score(y_val, val_prob.argmax(1),
6                           average="macro"))
6 best_alpha = float(alpha_grid[np.argmax(scores)])
7 hybrid_prob = best_alpha*cnn_test_prob + (1-best_alpha)*rf_test_prob
```



Mã nguồn 5: Khóa trọng số tổ hợp trên validation trước khi suy luận tập test

A.6. Suy luận trực tiếp cho ứng dụng demo

```
1  def infer_frame(bundle, modulation, channel, seed):
2      rng = np.random.default_rng(seed)
3      clean = generate_clean_frame(modulation, rng)
4      received, channel_meta = apply_channel(clean, channel, rng)
5
6      features = dsp_features(received)
7      rf_prob = bundle.rf.predict_proba(features.reshape(1, -1))[0]
8      cnn_input = torch.from_numpy(
9          cnn_tensor(received.reshape(1, -1))
10         ).to(bundle.device)
11     with torch.inference_mode():
12         cnn_prob = torch.softmax(bundle.cnn(cnn_input), dim=1)[0]
13         cnn_prob = cnn_prob.cpu().numpy()
14
15     hybrid_prob = (
16         bundle.alpha_cnn * cnn_prob
17         + (1.0 - bundle.alpha_cnn) * rf_prob
18     )
19     predicted_index = int(np.argmax(hybrid_prob))
20     return {
21         "received": received,
22         "channel": channel_meta,
23         "rf_probability": rf_prob,
24         "cnn_probability": cnn_prob,
25         "hybrid_probability": hybrid_prob,
26         "prediction": bundle.classes[predicted_index],
27     }
```

Mã nguồn 6: Điều phối bộ sinh tín hiệu, hai mô hình đã khóa và fusion cho một lần bấm nút

Mã đầy đủ của giao diện, engine DSP, cấu hình theme và launcher Windows nằm trong gói `24DTV_DKD2_22207056_LuongHaiLong_DemoApp_AMC.zip`. Hai tệp mô hình kèm gói là bản sao nén của artifact do notebook tạo, không phải mô hình huấn luyện riêng cho demo.

A.7. Đối chiếu nguồn mở

Kho TorchSig được khảo sát để hiểu cách một toolkit hiện đại tổ chức dữ liệu tín hiệu, lớp điều chế và impairment [11]. Bài báo CNN AMC của O'Shea và cộng sự định hướng cách đánh giá theo SNR [2].

Mã nguồn đồ án không sao chép module từ các kho trên. Bộ sinh, đặc trưng, CompactIQCNN, huấn luyện và hình vẽ đều nằm trong notebook nộp kèm; thư viện bên thứ ba được gọi qua API công khai.